

# APPLICATIONS DES RESEAUX DE NEURONES RECURRENTS POUR LA PREVISION DES ECOULEMENTS DANS LA VALLEE DU FLEUVE SENEGAL

---

*ALMAMY YOUSSEUF LY<sup>1\*</sup>, MAMADOU BOUSSO<sup>2</sup>, MOHAMED TALLA CISSE<sup>3</sup>, MOUHAMAD ALLAYA<sup>4</sup>, DAME SAMB<sup>5</sup>*

<sup>1</sup>Département des Sciences Expérimentales, UFR des Sciences et Technologies,

<sup>2</sup>Département de Management des Organisations, UFR Sciences Economiques et Sociales de  
l'Université Iba Der Thiam de Thiès, Sénégal.

---

**RESUME**-La prévision des régimes hydrauliques des fleuves a toujours été d'une grande importance dans la mesure où elle permet de prévenir certains phénomènes comme les inondations, la sécheresse d'une part, d'améliorer les productions agricoles et les navigations fluviales d'autre part.

Par conséquent, la recrudescence des inondations et les enjeux économiques constituent particulièrement les motivations de ce travail.

Dans notre article nous avons développé une application avec Streamlit capable de prédire le régime hydraulique journalier aux niveaux des stations de Bakel, de Matam et de Podor. L'algorithme prédictif qui a été utilisé est un modèle basé sur l'intelligence artificielle. Il s'agit précisément d'un variant des réseaux de neurones récurrents dénommé LSTM (Long Sort Term Memomry).

En outre, nous avons évalué les résultats de nos prévisions à l'aide des métriques suivants : le MAE (Mean Absolute Error) et le critère de Nash ( $R^2$ ). Il est ressorti au terme de cette étude que le modèle LSTM a obtenu de très bonnes performances.

**Mots clés :** *prévisions, réseaux de neurones récurrents, Long Sort Term Memory (LSTM), cotes, écoulements, bassin du fleuve Sénégal*

**ABSTRACT**-The prediction of the hydraulic regimes of rivers has always been of great importance insofar as it allows to prevent certain phenomena such as floods, drought on the one hand, and to improve agricultural productions and river navigations on the other hand.

Consequently, the increase of floods and the economic stakes constitute particularly the motivations of this work.

In our paper we developed an application with Streamlit capable of predicting the daily hydraulic regime at the stations of Bakel, Matam and Podor. The predictive algorithm that was used is a model based on artificial intelligence. It is precisely a variant of recurrent neural networks called LSTM (Long Sort Term Memomry).

In addition, we evaluated the results of our forecasts using the following metrics: the MAE (Mean Absolute Error) and the Nash criterion ( $R^2$ ). At the end of this study, we found that the LSTM model performed very well.

## 1. INTRODUCTION

A l'heure actuelle, les changements des conditions climatiques observés dans la zone tropicale depuis la fin des années 1960 et le début des années 1970 indiquent une tendance à la diminution de la pluviométrie en quantité et en durée dans de nombreux bassins versants plus précisément dans le fleuve Sénégal.

Ainsi, l'intérêt de notre étude repose sur des considérations d'ordre écologique et économique, notamment la revue documentaire, révélatrice d'informations objectives.

Aujourd'hui, la science des données est une discipline qui peut se faire une place de choix dans l'analyse et la prédiction des niveaux des cours d'eau sur un territoire quelconque. Sa démarche vient compléter celle des chercheurs en hydrologie, des géographes et des spécialistes en statistiques dont le centre d'intérêt est d'expliquer certains phénomènes liés à la hausse ou à la diminution des cotes.

Qui plus est, l'intérêt de mesurer et de prédire les niveaux d'eau se trouve aujourd'hui renforcé par les défis actuels que constituent le réchauffement climatique (les inondations, la sécheresse), les nouvelles demandes de partage de l'eau entre différents usages (énergétiques, irrigation, eau potable), la restauration ou la préservation des milieux naturels et de leur biodiversité, la demande sociale de connaissances et les vulnérabilités accrues de la société.

En effet, la mesure des débits d'une fleuve répond à plusieurs finalités : gestion opérationnelle d'ouvrages hydrauliques (aménagements hydro-électriques, systèmes d'irrigation, réservoirs d'écrêtement des crues ou de soutien des étiages...), dimensionnement de ces ouvrages, par la connaissance des caractéristiques de ces cours d'eau, contrôle réglementaire pour la vérification

des obligations de restitution de débit en aval d'ouvrages (débit minimum pour assurer la survie piscicole, le maintien d'autres usages ; la non aggravation des crues), la déclaration d'état de calamité (sécheresses...), la protection des biens et des personnes, par l'annonce des crues ; de patrimoine, par la constitution de séries d'observations de longue durée, indispensables pour connaître les évolutions des régimes des cours d'eau, sensibiliser les populations aux risques naturels, affecter une probabilité aux événements extrêmes (crues, étiages).

Ainsi, notre recherche qui s'ancre dans le bassin du fleuve Sénégal avec comme zone d'étude, les trois stations de la vallée du fleuve (en zone sahélienne), situées sur le cours même du fleuve entre les deux barrages, il s'agit principalement des stations de Bakel, de Matam et de Podor.

Dans cette démarche, on vise à développer et à déployer une application web basée sur un modèle d'apprentissage en profondeur tel que les LSMT capable de prédire les hauteurs d'eau journalières mesurées entre 1960 et 2008 au niveau du fleuve Sénégal.

## 2. PREVISION SUR LES SERIES TEMPORELLES : ETAT DE L'ART

Jusqu'à la fin des années 1990, les modèles stochastiques demeuraient les plus utilisés pour la prévision du débit des fleuves et des rivières. Parmi ces modèles on distingue la classe ARIMA (Auto Regressive Integrated Moving Average) proposé par Box et Jenkins en 1976 [1] et repris en 1990 par Mujumdar et Nagesh Kumar dans l'article Stochastic models of streamflow– Some case studies [2].

Cependant au cours de ces dernières années de nombreuses méthodes basées sur l'intelligence artificielle sont devenues populaires dans la

prévision des séries chronologiques suppléant au passage les techniques traditionnelles. Ceci s'explique par leur capacité à manier les gros volumes de données dans divers domaines.

Ainsi l'adaptabilité des réseaux de neurones récurrents dans l'hydrologie a été bien illustré dans ASCE (2000a) [3] et une liste de référence sur les applications des ANN en hydrologie est donnée dans ASCE (2000b) [4].

En 2004, D. Nagesh Kumar et al. [5], au terme d'une étude comparative sur des réseaux, ont recommandé d'utiliser les réseaux de neurones récurrents comme outil pour la prévision fluviale.

En 2018, lors de la 17<sup>ème</sup> Conférence internationale de l'IEEE sur l'apprentissage machine et ses applications, Sima Siyami-Namini et al. [6] ont démontré l'efficacité des prédictions effectuées par les algorithmes basés sur l'intelligence artificielle particulièrement les LSTM vis-à-vis du modèle classique à savoir Arima.

En 2020, Youchuan Hu et al. [7] ont montré l'importance des LSTM dans leurs travaux portant sur la prévision du débit des petites rivières basée sur une étude comparative entre les trois modèles suivants : LSTM (Long Short Term Memory), SVR (Support Vector Regression) et MLP (Multilayer Perceptions). En effet, en se basant sur le RMSE, le  $R^2$ , le MAE et le STA-LSTM, le modèle LSTM a obtenu les meilleures performances prédictives. Ce dernier a réussi à prévoir la hauteur d'eau à venir dans 6 heures en combinant les paramètres suivants : les cotes précédentes et la pluviométrie.

En 1999, Awadallah, Ayman Georges, dans sa thèse de Doctorat [8], a mis en place deux modèles de prévision du volume cumulé des apports naturels au niveau du Nil. Le premier est basé sur les fonctions de transferts avec bruit (FTB) et le second sur les réseaux de neurones artificiels (RNA). Les

entrées des modèles sont les températures de surface de l'océan (TSO) dans des régions déterminées ainsi que les volumes cumulatifs des apports naturels des années antérieures. Les résultats obtenus par les deux modèles sont plutôt satisfaisants car ils expliquent à 63% la variabilité des débits avec des coefficients de corrélations qui excèdent 0.85 entre les débits prédits et ceux observés.

Ainsi, la comparaison entre les FTB et les RNA a permis de tirer les deux conclusions suivantes. La première est que la relation entre les TSO dans l'Est du Pacifique et la crue du Nil peut être approximée par une relation linéaire à un degré acceptable de précision, vu que les résultats des modèles FTB et RNA sont similaires. La seconde est que les modèles FTB sont plus appropriés pour traiter le problème de la prévision à moyen terme des débits en utilisant l'information climatique.

En 2004, dans le cadre du programme "Risque d'Inondation" (RIO2), Sandrine Jenni et al. [9] ont mené une étude comparative et d'amélioration des outils de prévision dans le haut bassin de la Loire. Dans cet article, une quinzaine de bassins versants, d'une taille comprise entre 30 et 5000 km<sup>2</sup> au total ont été étudiés. D'une part, une approche basée sur les réseaux de neurones artificiels ont été utilisés pour faire progresser les modèles conceptuels et proposer une version à assimilation directe. Les résultats de cette approche ont été jugés satisfaisants. D'autre part, une méthode multi-modèle a été faite mais n'a pas remporté le succès escompté. Ce dernier a juste permis d'effectuer un calcul d'incertitude.

En 2009, Yonaba Harouna, dans sa thèse de doctorat [10], a remplacé le module BV3C (bilan vertical 3 couches) du modèle distribué HYDROTEL par un ensemble de réseaux de neurones.

Les conclusions tirées des différents tests effectués montrent tout d'abord que la substitution donne des résultats satisfaisants et un léger gain de temps dans

l'exécution du processus. De plus, le critère de bilan et l'erreur moyenne absolue indiquent que les réseaux de neurones dépassent en termes de performance le module BV3C.

En 2014, Johanet et al. [11] ont abordé la modélisation hydrodynamique des karsts à l'aide des réseaux de neurones artificiels. Dans cet article, ils ont montré l'efficacité des modèles mathématiques issus de l'intelligence artificielle dans leur capacité à modéliser parfaitement l'hydrodynamique des aquifères karstiques.

En 2018, Yaseen et al. [12] ont développé un modèle d'apprentissage automatique axée sur les données, à savoir l'Extreme Learning Machine (ELM). Il a été mis en œuvre dans la prévision de débit du fleuve Johor en Malaisie. Elle a ensuite été comparée avec un autre modèle de machine de Learning : les ANN (Artificial Neural Network). Les métriques  $R^2$ , RMSE et MAE ont ainsi montré que ELM est plus performant que les ANN en termes de précision et de temps.

En 2019, Bastien NONY, dans le cadre de son stage au Centre européen de recherche et de formation avancée en calcul scientifique (CERFACS) [13] a participé à la conception de modèle capable de prédire la hauteur d'eau au niveau de Toulouse sur une échéance de 6h. Primo, les modèles statistiques qui ont été entraînés sur l'ensemble de la base de données ont aboutis à de mauvais résultats entraînant au passage la réduction de la quantité des données. Secundo, des modèles tels que la régression linéaire, SVM (Support Vector Machine), gradient boosting,  $\epsilon$ -SVR et un réseau de neurones de type MLP (Perceptron multicouches) ont été mise en place pour faire des prédictions de 4h à 6h. Dans ce cas de figure, les résultats obtenus sont plutôt satisfaisants.

En 2020, Syed Kabir et al. [14] ont développé une approche de modélisation basée sur une méthode de réseau de neurones à convolution profonde (CNN)

pour la prédiction rapide des inondations fluviales à Carlisle, au Royaume-Unis. Pour évaluer les performances de ce modèle, ce dernier a été comparé au Support Vector Machine (SVR). Au final, les résultats ont montré que le CNN surpasse largement SVR.

En 2020, Yuka Ding et al. [15] ont proposé un modèle interprétable de mémoire à court terme et d'attention spatio-temporelle (STA-LSTM) basé sur le LSTM et le mécanisme d'attention. Cette méthode a été développée pour pallier aux limites des solutions déjà existantes pour la prédiction en hydrologie. Les résultats des expériences menées sur trois petits et moyens bassins en Chine suggèrent que le modèle STA-LSTM surpasse la moyenne historique (HA), les réseaux convolutifs graphiques (GCN), le LSTM original (LSTM), l'attention spatiale LSTM (SA-LSTM) et l'attention temporelle LSTM (TA-LSTM) dans la plupart des cas.

### 3. MATERIEL ET METHODES

#### 3.1. Zone de l'étude

Le fleuve Sénégal long de 1086 km, couvre une superficie d'environ 300 000 km<sup>2</sup> et traverse le Sénégal, la Mauritanie, le Mali et la Guinée. Il est le deuxième cours d'eau le plus important de l'Afrique de l'Ouest après le Niger.

Le bassin comprend trois régions principales : le Haut-bassin, la vallée et le Delta. Ces régions se différencient fortement par leurs conditions topographiques et climatologiques.

Ce bassin versant qui s'étend des zones tropicales humides (1500 mm/an dans la partie guinéenne) aux zones tropicales sèches (200-250 mm/an dans la partie septentrionale du bassin) traverse des milieux biophysiques diversifiés du haut bassin situé dans les montagnes du Fouta Djallon (encore appelées château d'eau de l'Afrique) au delta, en passant à

travers des zones subdésertiques. Dans ce bassin versant vivent environ 3,5 millions de personnes qui tirent l'essentiel de leurs revenus des ressources du milieu [16].

En 1972, ces Etats, traversés par le fleuve, ont créé l'OMVS (Organisation pour la Mise en Valeur du Fleuve Sénégal) dans l'optique d'exploiter au mieux les ressources et les opportunités offerts par le fleuve. De ce fait, des programmes de développement axés sur l'irrigation, la production d'énergie hydroélectrique et la navigation ont été lancés. Ainsi les barrages de Diama et de Manantali ont été construits. Par conséquent, le secteur agricole et les villes riveraines se sont développés.

La zone d'étude s'étend sur le bassin aval du fleuve Sénégal et concerne particulièrement les stations de Bakel, de Matam et de Podor. Les données utilisées sont les hauteurs d'eau journalière mesurés entre 1960 et 2008.

### 3.2. Logiciels de traitement des données

Nous avons effectué le traitement des données avec l'aide de Jupyter Notebook qui est un environnement de développement interactif basé sur le Web pour les blocs-notes, le code et les données. Quant à l'application, elle a été réalisée à l'aide du framework Streamlit.

### 3.3. Modèles

Dans notre travail, nous avons choisi un modèle basé sur l'intelligence artificielle. Il s'agit d'une variante des réseaux de neurones récurrents dénommé les réseaux de mémoires à court terme communément appelé en anglais Long Sort Term Memory (LSTM).

#### A. Les réseaux de mémoires à long terme (Long Sort Term Memory : LSTM)

Développés pour la première fois vers les années 1980, les réseaux de neurones récurrents sont des réseaux dans lesquels l'information peut se propager dans les deux sens, y compris des couches profondes aux premières couches [7]. Ces réseaux possèdent des connexions récurrentes au sens où elles conservent des informations en mémoire : ils peuvent prendre en compte à un instant un certain nombre d'états passés.

La logique de base et classique du RNN est présentée ci-dessous :

$$h_t = f_h(x_t, h_{t-1}) = \phi_h(W^T h_{t-1} + U^T x_t) \quad (1)$$

$$y_t = f_o(h_t, x_t) = \phi_o(V^T h_t) \quad (2)$$

Où  $x_t$  est l'entrée,  $h_t$  représente l'état caché et  $y_t$  est la sortie, l'indice  $t$  représente le temps.

Tout d'abord la sortie du dernier état caché est combiné avec l'entrée actuelle (chacune avec les poids  $W^T$  et  $U^T$ ), dont le résultat est transformé par une fonction non linéaire tanh ou sigmoïde, puis est introduit dans l'état caché. Ensuite l'état caché prend son poids  $V^T$ , il est transformé par une autre fonction non linéaire et le résultat est finalement affecté à  $y_t$ . De cette façon, la sortie actuelle  $y_t$  est affectée au dernier état caché, ce qui permet d'obtenir une courte mémoire.

Bien que les RNN sont très pratiques pour le traitement des données séquentielles, il s'avère qu'ils sont extrêmement difficiles à entraîner pour gérer la dépendance à long terme en raison du problème de la disparition du gradient (Gradient Vanishing).

Pour surmonter le problème du vanishing gradient, les réseaux de neurones à mémoire long terme (Long Sort Term memory : LSTM) ont été introduits par

Hochreiter, Schmidhuber et al. en 1997 [17], puis amélioré dans l'article de F. Gers et J. Schmidhuber [18].

Les LSTM utilisent des cellules de mémoire et des portes pour contrôler l'information sauvegardée dans le réseau [19]. Autrement dit c'est une série de portes et de cellules qui coopèrent pour produire un résultat final. Une passe avant d'un réseau de neurones LSTM est modélisée par les équations (3-8).

$$f_t = \sigma(W_f \cdot x_t + U_f \cdot h_{t-1} + b_f) \quad (3)$$

$$i_t = \sigma(W_i \cdot x_t + U_i \cdot h_{t-1} + b_i) \quad (4)$$

$$\tilde{c}_t = \tanh(W_c \cdot x_t + U_c \cdot h_{t-1} + b_c) \quad (5)$$

$$c_t = f_t * c_{t-1} + i_t * \tilde{c}_t \quad (6)$$

$$o_t = \sigma(W_o \cdot x_t + U_o \cdot h_{t-1} + b_o) \quad (7)$$

$$h_t = o_t * \tanh(c_t) \quad (8)$$

Où  $U$  et  $W$  sont les poids des entrées dans les différentes portes : la porte d'entrée ( $i_t$ ), la porte de modulation d'entrée ( $c_t$ ), la porte d'oubli ( $g_t$ ) et la porte de sortie ( $o_t$ ).

$b$  est le vecteur de biais,  $c_t$  est l'état de la cellule et  $h_t$  est l'état caché.

Tous ces paramètres déterminent la quantité d'informations à recevoir de la dernière boucle et celle à transmettre au nouvel état. En choisissant activement les informations utiles à stocker et à rejeter, les LSTM apportent une solution au problème d'explosion et de disparition du gradient auquel sont confrontés les RNN.

## 2.4 Méthodes de modélisations

### A. Acquisition des données

Les données de l'étude ont été collectées à partir de la base de données de l'OMVS (Organisation pour la Mise en Valeur du Fleuve

Sénégal) et de la DGRPE (Direction de la Gestion et de la Planification des Ressources en Eau du Sénégal).

Elles sont constituées des hauteurs d'eau journalières relevées entre 1960 et 2008 au niveau des stations de Bakel, Matam et Podor. Chaque station possède 366 enregistrements répartis dans 49 colonnes.

### B. Prétraitement des données

Dans cette partie, nous avons transformé les données initiales de chaque station en des tableaux constitués uniquement de deux colonnes : la date et la hauteur d'eau. Cela nous a permis d'obtenir exactement pour chaque journée le niveau d'eau qui a été relevé. Ainsi nous passons à des tableaux de 366 enregistrements et 49 colonnes, à des dataframes constitués de 17 532 enregistrements répartis dans 2 colonnes.

Les données manquantes ont été traitées avec la méthode d'interpolation qui consiste à estimer des points de données inconnus entre deux points de données connus.

Ensuite nous avons vérifié la stationnarité des données qui décrit le fait que la série temporelle a une moyenne, une variance et une covariance constantes et qu'elles ne dépendent pas du temps. C'est le test Dickey Fuller qui a été utilisé et les résultats sont représentés graphiquement au niveau de la Figure 2. Ainsi, nous remarquons que les valeurs des p-values de chacune des stations étant inférieures à 5% donc on rejette l'hypothèse nulle ce qui signifie que nos données sont stationnaires.

Avec le package `seasonal` de la bibliothèque `statsmodels` de python, nous avons effectué une décomposition saisonnière. Ce qui nous a conduit à observer la présence de la saisonnalité, la tendance et les résidus sur la Figure 3.

D'une manière générale, on observe une tendance quasiment similaire dans les stations. Elle met en évidence trois périodes : une succession d'année humide notée entre 1960 et 1970, suivi d'une succession d'année sèche, du début des années 1970 au milieu des années 1990. Enfin, on remarque dans les années 1990, un retour des années humides [16]. On peut donc dire que nos séries présentent des saisonnalités.

Par suite, les données ont été divisées en deux ensembles, l'un pour les données d'apprentissage et l'autre pour les données de test. On a donc pris 85% des observations comme données d'apprentissage contre 15% pour les données de test.

Cependant, vue que les réseaux de neurones LSTM sont sensibles à l'échelle des données d'entrée, on a eu à les redimensionnées à l'aide de la fonction MinMaxScaler de la bibliothèque Scikit Learn. En effet, cet estimateur met à l'échelle et traduit chaque caractéristique individuellement de sorte qu'elle se trouve dans une plage de donnée sur l'ensemble d'apprentissage, dans notre cas entre 0 et 1. Sa formule mathématique est définie ci-dessous :

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (9)$$

De plus, nous avons défini une fonction qui prend en argument le dataset et le look\_back qui est le nombre de pas de temps antérieur à utiliser comme variables d'entrée pour prédire la prochaine période de temps par défaut elle est égale à 1.

Cette valeur par défaut permettra de créer un ensemble de données où X est la hauteur d'eau à un instant donné (t) et Y est la hauteur d'eau à l'instant suivant (t + 1).

En outre, les LSTM s'attendent à ce que les données d'entrée X soient fournies avec une structure de tableau spécifique sous la forme de : [échantillons,

pas de temps, caractéristiques] car les données d'entrée sont sous la forme [échantillons, caractéristiques]. Vue que nous encadrons le problème à un pas de temps pour chaque échantillon, il a été nécessaire de transformer les données d'entrée dans la structure attendue à l'aide de la fonction reshaping disponible dans le notebook.

### C. Entraînement des modèles

Notre modèle LSTM fonctionne à l'aide de plusieurs couches de réseaux empilés. On sait qu'une couche LSTM nécessite une entrée tridimensionnelle et que les LSTM produiront par défaut une sortie bidimensionnelle comme interprétation à partir de la fin de la séquence. Pour résoudre ce problème on génère à l'aide du LSTM une valeur pour chaque pas de temps dans les données d'entrée en définissant return\_sequences à True sur la couche. Cela nous permettra d'avoir une sortie en 3 dimensions de la couche LSTM cachée comme entrée pour la suivante. Par expérience, la fonction d'activation sigmoïde a été choisi pour les blocs LSTM.

Au niveau de l'input\_shape, le modèle prend comme argument le nombre de pas de temps et le nombre de caractéristique. Comme nous travaillons avec une série univariée le nombre de pas de temps est x\_train.shape[1] et le nombre de pas en entrée est x\_train.shape[2].

Au premier niveau de la dernière couche cachée, nous avons 128 unités dans chaque couche et la couche dense de taille 1 est la couche de sortie.

Le modèle est ajusté à l'aide d'Adam et optimisé à l'aide de l'erreur quadratique moyenne, ou fonction de perte (mse).

Grâce aux lots, le modèle se met à jour plusieurs fois avant de traiter l'ensemble des données. Une petite taille de lot ralentit considérablement la vitesse

d'apprentissage et une grande taille de lot cause un surapprentissage [7]. Dans notre expérience la taille des lots a été fixée à 32.

Une fois le modèle ajusté, nous estimons d'abord les performances du modèle sur les ensembles de données d'entraînement puis sur les valeurs de test.

#### D. Critères d'évaluations

Dans cet article, deux métriques ont été utilisées comme critères d'évaluation. Il s'agit des critères de Nash et l'erreur absolue moyenne (MAE : Mean Absolute Error).

La MAE est une méthode de mesure courante pour montrer la différence entre la valeur prédite et la valeur observée et dont l'erreur est linéaire. De plus une MAE plus faible signifie une meilleure prédiction. Sa formule mathématique est la suivante :

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i| \quad (10)$$

Où m représente le nombre total de valeurs,  $y_i$  la valeur observée et  $\hat{y}_i$  la valeur prédite.

Le critère de Nash-Sutcliffe est fondé sur la somme des carrés des écarts entre les valeurs observées et les valeurs simulées [20]. Il a été bâti de façon à permettre la comparaison entre des événements présentant des ordres de grandeur de débits différents. Il diffère de la mesure précédent en ce sens que l'échelle du résultat ne dépend pas de l'échelle de l'entrée. Dans la plupart des cas, sa valeur se situe entre 0 et 1.

Une valeur positive élevée signifie une meilleure prédiction alors que l'effet contraire est le signe d'une inadaptation du modèle et une valeur nulle signifie que le modèle ne donne pas de meilleur résultat qu'un modèle basique donnant à chaque pas

de temps un débit constant égal à la moyenne des débits observés. Sa formule mathématique est la suivante :

$$Nash = 1 - \frac{\sum_{i=1}^m (y_i - \bar{y})^2}{\sum_{i=1}^m (y_i - \hat{y}_i)^2} \quad (11)$$

Où m représente le nombre total de l'échantillon,  $y_i$  le débit observé,  $\hat{y}_i$  le débit prédit et  $\bar{y}$  est la moyenne des débits observés.

### 3. RESULTAS

Une fois que les données des différentes stations ont été prétraitées, puis divisées en deux échantillons, l'un pour l'entraînement et l'autre pour le test, elles ont finalement été transmises à nos trois modèles qui y ont effectuées des prévisions. Les métriques de ce processus sont enregistrées dans le tableau 2 et les prédictions ont été visualisées dans la figure 4.

De ce fait, nous constatons que le modèle LSTM a obtenu de très bonne performance. De surcroît la figure 4 montre que les prévisions effectuées sur les débits de test correspondent presque parfaitement aux situations réelles. Outre cela, ces résultats prouvent que la capacité de mémoire d'oubli des LSTM aide grandement ce dernier à prédire les données non linéaires et les séries temporelles [7].

Concernant la technique prévisionnelle utilisée avec le modèle LSTM, elle est basée sur la méthode de la fenêtre de déplacement qui consiste à sélectionner un ensemble bien défini des données de test. Ensuite, elle fait une prédiction d'une unité puis se déplace d'une unité et refait une autre prédiction. Elle poursuit cette opération jusqu'à un terme fixé du nombre de jour à prédire.

Dans notre travail, nous nous sommes appuyés sur les relevés de la dernière année pour effectuer les



prévisions dans le futur. Un exemple de visualisation de la hauteur d'eau prévue dans 5 jours au niveau de chacune des stations est disponible dans la figure 5.

**Tableau 2. Tableau des métriques**

*Table 2. Metrics Table*

Stations	Métriques	
	MAE	NASH
Bakel	14.13	0.98
Matam	8.18	0.99
Podor	2.38	0.99

#### 4. DISCUSSION

Les résultats prouvent que les données historiques des débits jouent un rôle important dans la précision des prévisions de notre modèle. D'après le tableau 2, les LSTM ont réalisé des performances prévisionnelles largement satisfaisante car les valeurs des MAE et des critères de Nash sont respectivement proches de 0 et proche de 1.

En plus de cela, cette efficacité remarquable s'explique par une approche basée sur un algorithme d'optimisation itératif. Par itératif, nous entendons obtenir des résultats plusieurs fois, puis sélectionner le plus optimal, c'est à dire l'itération qui minimise les erreurs. Par conséquent, les itérations et le réglage des autres hyperparamètres à savoir entre autres la taille des lots, l'optimiseur Adam choisi ont permis à notre modèle LSTM de s'adapter aux données. A cela, il faut aussi ajouter le travail de prétraitement qui a été effectué au préalable, il est d'une importance capitale dans la mesure où

il a fortement impacté sur le produit final c'est-à-dire la sortie de nos données.

#### 5. CONCLUSION

La prévision fluviale revêt toujours une importance capitale pour la préservation des vies humaines, de leur bien et des catastrophes naturelles.

Dans cet article, nous avons développé une application capable de prédire le régime hydraulique du fleuve Sénégal à l'aide du modèle LSTM. Au terme de cette étude, les résultats du MAE et du  $R^2$  ont permis de tirer des conclusions satisfaisantes sur la capacité prédictive de la méthode utilisée.

Cependant il y'a encore place à l'amélioration avec la méthode de prévision. Les résultats montrent quelques erreurs dans les pics de prévision qui ne peuvent être ignorées. Il suffit de continuer à ajuster les hyperparamètres du modèle, d'entraîner et de comparer les performances en vue d'obtenir le modèle optimum c'est-à-dire celui qui minimise au mieux les erreurs.

Qui plus est, nous viserons dans nos prochains travaux à développer ses performances en faisant des études comparatives avec des modèles d'intelligence artificielle et de statistiques.

Tableau 1. Caracterisation des stations hydrometriques du bassin du fleuve senegal [16]

Table 1. Characterization of the hydrometric stations of the senegal river basin

Stations étudiées	Bassin Aval (influencée par les barrages)		
	Bakel	Matam	Podor
Longitude	12°27' W	13°15' W	14°57' W
Latitude	14°54' N	15°39' N	16°39' N
Altitude (Zéro de l'échelle en m IGN)	11,16	6,32	-0,44
Superficie du bassin versant amont (km <sup>2</sup> )	218 000	230 000	266 000
Années d'installation station	1901	1903	1903
Paramètres mesurés	Débit et cotes	Débit et cotes	Cotes
Période de suivi	1904-2011	1903-2011	1903-2011
Période étudiée	1960-2008	1960-2008	1960-2008

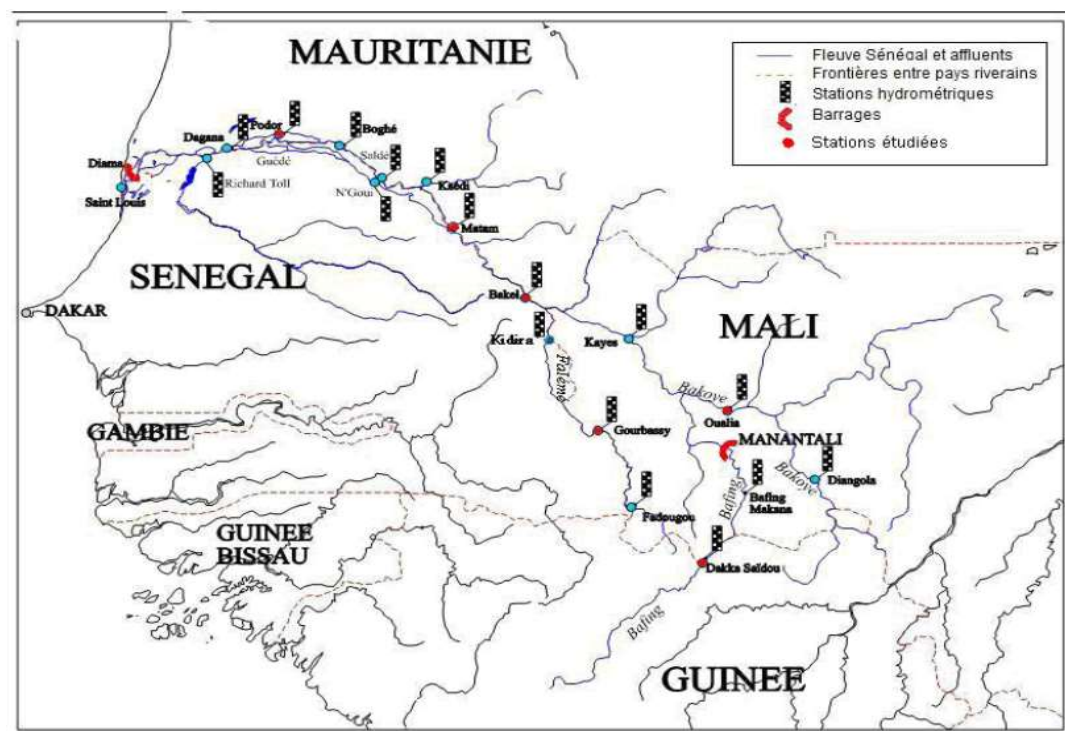

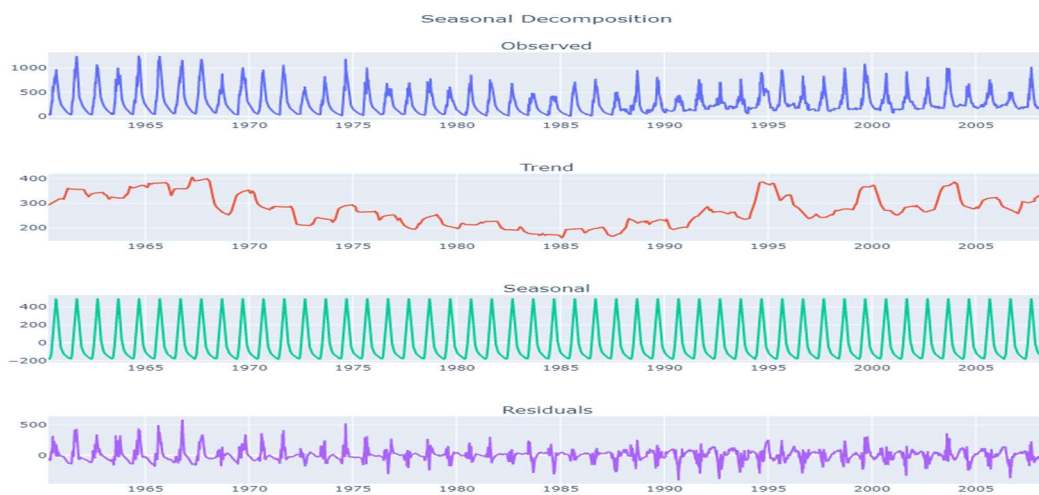


Figure 1. Réseau de suivi hydrologique du fleuve senegal [16]


Hydrological monitoring network of the senegal river




**Figure 2 : Vérification de la stationnarité**  
*Verification of the stationarity*



***Figure 3a : Décomposition saisonnière pour la station de Bakel***




***Figure 3b : Décomposition saisonnière pour la station de Matam***




***Figure 3c : Décomposition saisonnière pour la station de Podor***


**Figure 3 : Décomposition saisonnière**  
***Seasonal decomposition***



**Figure 4a.** Prédiction sur les données de test pour la station de Bakel

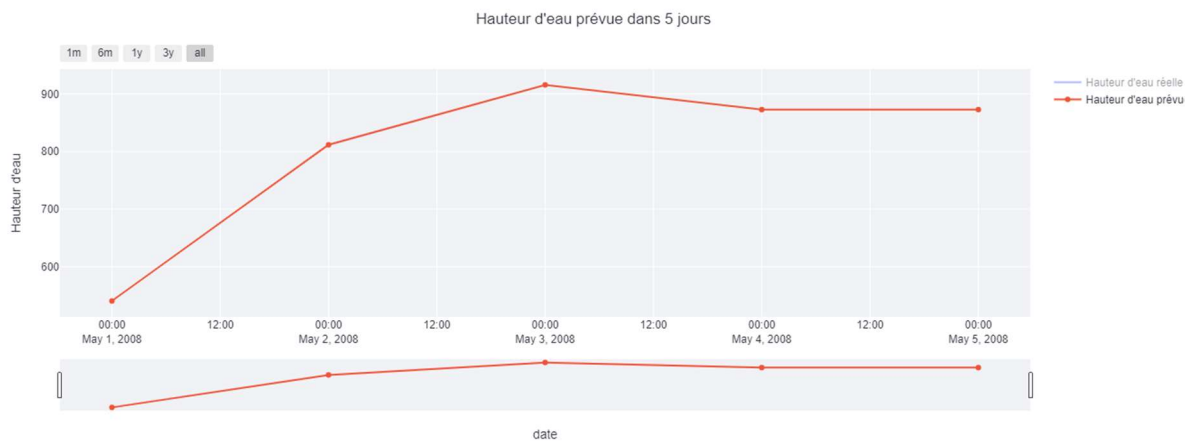


**Figure 4b.** Prédiction sur les données de test pour la station de Matam

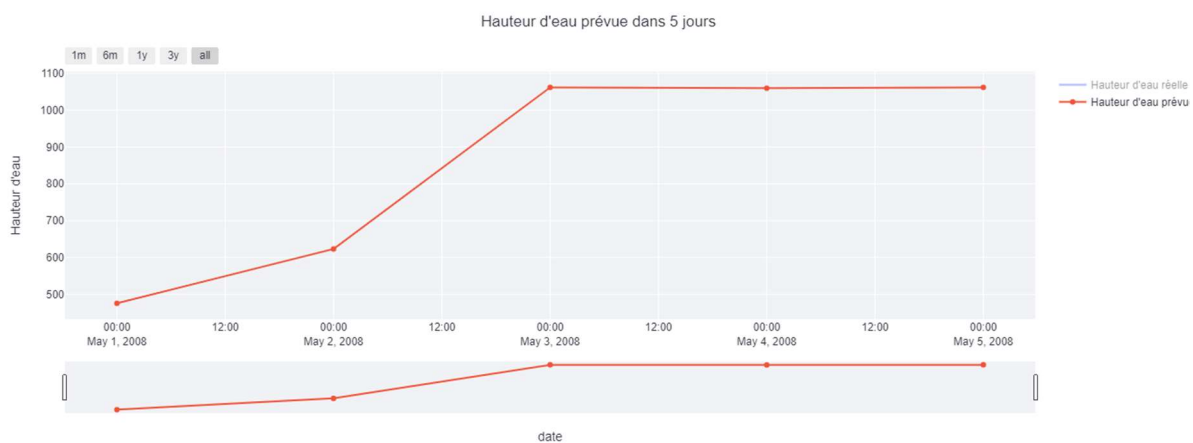


**Figure 4c.** Prédiction sur les données de test pour la station de Podor


**Figure 4.** Prédiction sur les données de test au niveau des trois stations à l'aide du modèle LSTM  
Prediction on test data at the three stations using the LSTM model



**Figure 5a. Hauteur d'eau prévue dans 5 jours au niveau des 3 stations**



**Figure 5b. Hauteur d'eau prévue dans 5 jours au niveau des 3 stations**



**Figure 5c. Hauteur d'eau prévue dans 5 jours au niveau des 3 stations**

**Figure 5. Hauteur d'eau prévue dans 5 jours au niveau de chacune des 3 stations**  
*Water level expected in 5 days at each of the 3 stations*

## REFERENCES BIBLIOGRAPHIQUES

- [1] Box, G.E.P. and Jenkins, G.M. (1976) Time Series Analysis: Forecasting and Control. Revised Edition, Holden Day, San Francisco.
- [2] Mujumdar, P. P. and Nagesh Kumar, D. : 1990, 'Stochastic models of streamflow– Some case studies', Hydrol. Sci. J. 35, 395–410.
- [3] ASCETask Committee on Application of Artificial Neural Networks in Hydrology: 2000a, 'Artificial neural networks in hydrology. I: Preliminary concepts', J. Hydrol. Engineer. ASCE 5(2), 115123.
- [4] ASCETask Committee on Application of Artificial Neural Networks in Hydrology: 2000b, 'Artificial neural networks in hydrology. II : Hydrologic applications', J. Hydrol. Engineer., ASCE 5(2), 124–137
- [5] D. NAGESHKUMAR1, K. SRINIVASARAJU and T. SATHISH3
- River Flow Forecasting using Recurrent Neural Networks, WaterResources Management 18: 143–161, 2004
- [6] Sima Siامي-Namini, Neda Tevakoli, Akbar Siامي Namin.
- A Comparison of ARIMA and LSTM in Forecasting Time Series. 2018 17th IEEE International Conference on Machine Learning and Applications, pp. 1394-1401.
- [7] Yochuan Hu, Le Yan, Tingting Hang, Jun Feng. Stream-flow forecasting of small rivers based on LSTM. arXiv : 2001. 05681v1 [cs. LG] 16 Jan 2020.
- [8] Awadallah, Ayman Georges. Hydro-climatologie globale pour la prévision des crues du Nil au moyen de fonctions de transfert avec bruit et de réseaux de neurones artificiels. Ecole Polytechnique de Montréal, 1999.
- [9] Andréassian, Vazken, Sandra Jenni, Ludovic Oudin, Charles Perrin, Thibault Mathevet, Claude Michel, Jean-Louis Rosique, Mamoutou Tangara, François Anctil et Nicolas Lauzon. « Prévision des crues sur le bassin amont de la Loire à partir de modèles pluie-débit globaux et de réseaux de neurone ». Rapport au programme RIO2., Ministère de l'Environnement, Paris, 2004.
- [10] Yonaba, Harouna. « Modélisation hydrologique hybride : réseau de neurones-modèles conceptuel », 2009.
- [11] Johannet, Anne, Virgile Taver, Line Kong a Siou, Valérie Borrell Estupina, Séverin Pistre, Alain Mangin, Bernand Vayssade, Marc Vinches et Dominique Bertin. « Les réseaux de neurones artificiels pour la modélisation hydrodynamique des aquifères karstique. » Karstologia 60 (2014) : 45-59.
- [12] Yaseen, Zaher Mundher, Mohammed Falah Allawi, Ali A. Yousif, Othman Jaafar, Firdaus Mohamad Hamzah, et Ahmed El-Shafie. « Non-tuned machine learning approach for hydrological time series forecasting ». Neural Computing and Applications 30, no 5 (2018) : 1479-91.
- [13] Nony, « Prédiction et reconstruction de données hydrauliques par apprentissage ».
- [14] Kabir, Syed, Sandhya Patidar, Xilin Xia, Qihua Liang, Jeffrey Neal et Gareth Pender. « A deep convolutional neural network model for rapid prediction of fluvial flood inundation ». Journal of Hydrology 590 (2020) : 125481.
- [15] Ding, Yukai, Yuelong Zhu, Jun Feng, Pengcheng Zhang et Zirun Cheng. « Interpretable spatio-temporal attention LSTM model for flood forecasting ». Neurocomputing 403 (202) : 348-59
- [16] Mouhamed Talla Cisse, Soussou Sambou, Yaya Dieme, Clément Diatta et Mamadou Bop.
- Analyse des écoulements dans le bassin du fleuve Sénégal de 1960 à 2008, Revue des Sciences de l'Eau, Volume 27, numéro 2, 2014, pp. 167-187
- [17] S. Hochreiter, J. Schmidhuber, "Long Short-Term Memory," *Neural Computation* 9(8) : 1735-1780, 1997.
- [18] Felix A. Gers, Nicol N. Schraudolph, Jürgen Schmidhuber
- Learning Precise Timing with LSTM Recurrent Networks. Journal of Machine Learning Research 3 (2002) 115-143
- [19] Stérin, Tristan. « Réseaux de neurones récurrents et mémoire : application à la musique », 2016
- Prévision des crues dans le bassin amont du fleuve Sénégal à l'aide de procédure adaptatives, LJEE N° 21 et 22. Spéciale colloque CIREDD' 2013, pp. 65-75
- [20] Soussou Samabou, Séni Tamba, Mouhamed Talla Cissé, Yaya Diémé.